

Московский Авиационный Институт
(Национальный Исследовательский Университет)
Институт №8 “Компьютерные науки и прикладная математика”
Кафедра №806 “Вычислительная математика и программирование”

Лабораторная работа №2 по курсу
«Операционные системы»

Группа: М8О-209Б-24

Студент: Филь Н.А.

Преподаватель: Миронов Е.С.

Оценка: _____

Дата: 10.11.25

Москва, 2025

Постановка задачи

Вариант 19.

Реализация многопоточной программы для кластеризации методом k-средний с ограничением максимального количества потоков.

Общий метод и алгоритм решения

В лабораторной работе использованы системные вызовы POSIX:

- `int pthread_create(...)` – создание нового потока;
- `int pthread_join(...)` – ожидание завершения потока;
- `int sem_wait(...), sem_post(...)` – ограничение числа активных потоков;
- `int pthread_mutex_lock(...), pthread_mutex_unlock(...)` – синхронизация общих данных;
- `execve(), clone(), futex()` – низкоуровневые системные вызовы, фиксируемые в `strace` при запуске программы.

Алгоритм:

В лабораторной работе реализована многопоточная обработка данных с использованием POSIX-потоков (`pthread`). Для ограничения числа активных потоков используется семафор. Синхронизация флага изменения кластеров осуществляется через мьютекс. Каждый поток обрабатывает часть массива точек, вычисляя ближайший кластер. После завершения всех потоков пересчитываются центры кластеров, и процесс повторяется до достижения сходимости.

Код программы

lab2.cpp

```
#include <iostream>
#include <vector>
#include <cmath>
#include <pthread.h>
#include <semaphore.h>
#include <chrono>
#include <random>
#include <mutex>

using namespace std;

struct Point {
    double x, y;
    int cluster;
};

struct Cluster {
    double x, y;
};

vector<Point> points;
vector<Cluster> clusters;
int k;
int maxThreads;
bool changed = true;

sem_t thread_sem;
pthread_mutex_t mutex_sum;

double distance(const Point &a, const Cluster &b) {
    return sqrt(pow(a.x - b.x, 2) + pow(a.y - b.y, 2));
}
```

```

}

void* assign_points(void* arg) {
    long id = (long)arg;
    size_t total_points = points.size();
    size_t points_per_thread = total_points / maxThreads;

    size_t start = id * points_per_thread;
    size_t end = (id == maxThreads - 1) ? total_points : start + points_per_thread;

    bool local_changed = false;

    for (size_t i = start; i < end; ++i) {
        double min_dist = 1e9;
        int cluster_index = 0;

        for (int j = 0; j < k; ++j) {
            double dist = distance(points[i], clusters[j]);
            if (dist < min_dist) {
                min_dist = dist;
                cluster_index = j;
            }
        }

        if (points[i].cluster != cluster_index) {
            points[i].cluster = cluster_index;
            local_changed = true;
        }
    }

    if (local_changed) {
        pthread_mutex_lock(&mutex_sum);
        changed = true;
        pthread_mutex_unlock(&mutex_sum);
    }

    sem_post(&thread_sem);
    return nullptr;
}

void update_clusters() {
    vector<double> sum_x(k, 0.0), sum_y(k, 0.0);
    vector<int> count(k, 0);

    for (auto &p : points) {
        sum_x[p.cluster] += p.x;
        sum_y[p.cluster] += p.y;
        count[p.cluster]++;
    }

    for (int i = 0; i < k; ++i) {
        if (count[i] > 0) {
            clusters[i].x = sum_x[i] / count[i];
            clusters[i].y = sum_y[i] / count[i];
        }
    }
}

int main(int argc, char* argv[]) {
    if (argc < 2) {
        cout << "Использование: ./lab4 <макс_потоков>\n";
        return 1;
    }

    maxThreads = stoi(argv[1]);
    cout << "Введите число кластеров: ";
    cin >> k;

    int n;
    cout << "Введите количество точек: ";
    cin >> n;

    random_device rd;
    mt19937 gen(rd());

```

```

uniform_real_distribution<> dis(0, 100);

points.resize(n);
for (auto &p : points) {
    p.x = dis(gen);
    p.y = dis(gen);
    p.cluster = rand() % k;
}

clusters.resize(k);
for (auto &c : clusters) {
    c.x = dis(gen);
    c.y = dis(gen);
}

sem_init(&thread_sem, 0, maxThreads);
pthread_mutex_init(&mutex_sum, nullptr);

auto start_time = chrono::high_resolution_clock::now();

while (changed) {
    changed = false;

    vector<pthread_t> threads(maxThreads);

    for (int i = 0; i < maxThreads; ++i) {
        sem_wait(&thread_sem);
        pthread_create(&threads[i], nullptr, assign_points, (void*)(long)i);
    }

    for (int i = 0; i < maxThreads; ++i) {
        pthread_join(threads[i], nullptr);
    }

    update_clusters();
}

auto end_time = chrono::high_resolution_clock::now();
auto duration = chrono::duration_cast<chrono::milliseconds>(end_time - start_time).count();

cout << "\nАлгоритм завершён.\nВремя выполнения: " << duration << " мс\n";

sem_destroy(&thread_sem);
pthread_mutex_destroy(&mutex_sum);
return 0;
}

```

Протокол работы программы

Тестирование:

```
n1k@n1k-vim:~/Documents$ g++ -pthread -std=c++17 lab2.cpp -o lab2
```

```
n1k@n1k-vim:~/Documents$ ./lab2 4
```

Введите число кластеров: 3

Введите количество точек: 1000

Алгоритм завершён.

Время выполнения: 64 мс

Strace:

Фрагмент вывода strace (ключевые места):

1. Запуск программы:

```
3527 execve("./lab2", ["/lab2", "4"], 0xfffff832c9f0 /* 75 vars */) = 0
```

Системный вызов `execve()` используется ядром Linux для запуска исполняемого файла с аргументами.

2. Создание потоков

```
3527 clone(child_stack=..., flags=CLONE_VM|CLONE_FS|CLONE_FILES|
CLONE_SIGHAND|CLONE_THREAD|CLONE_SYSVSEM|CLONE_SETTLS|
CLONE_PARENT_SETTID|CLONE_CHILD_CLEARTID, parent_tid=[3552], ...) = 3552
3527 clone(child_stack=..., flags=CLONE_VM|CLONE_THREAD|CLONE_SIGHAND|...) = 3553
3527 clone(child_stack=..., flags=CLONE_VM|CLONE_THREAD|CLONE_SIGHAND|...) = 3554
```

Системный вызов `clone()` — это низкоуровневая реализация создания потоков в Linux. Флаг `CLONE_THREAD` указывает, что создаются **POSIX-потоки**, а не отдельные процессы. Каждый вызов `pthread_create()` в коде соответствует системному вызову `clone()` в логе strace.

3. Синхронизация потоков

```
3527 futex(0xffff9e816290, FUTEX_WAIT, 3571, NULL)
3527 futex(0xffff9f017290, FUTEX_WAIT, 3570, NULL)
```

Системный вызов `futex()` используется библиотекой `pthread` для реализации механизмов синхронизации, таких как:

- ожидание завершения потоков (`pthread_join`);
- блокировка мьютексов (`pthread_mutex_lock`);
- работа семафоров (`sem_wait`, `sem_post`).

Появление вызова `futex` подтверждает, что синхронизация потоков выполняется корректно и с использованием POSIX-примитивов.

4. Работа с памятью и вводом/выводом

```
mmap(NULL, 8192, PROT_READ|PROT_WRITE, MAP_PRIVATE|MAP_ANONYMOUS, -1, 0)
write(1, "Алгоритм завершён.\n", 20) = 20
```

`mmap()` — выделяет память под стеки потоков и другие структуры данных программы.
`write()` — выполняет системный вывод информации в стандартный поток вывода.

5. Завершение потоков

```
3552 exit(0)
3553 +++ exited with 0 +++
```

Каждый поток завершается системным вызовом `exit(0)`, что свидетельствует о корректном завершении без ошибок.

Анализ

Число потоков	Время исполнения (мс)	Ускорение	Эффективность
1	16874	1,00	1,000
2	8300	2,03	1,016
3	4075	4,14	1,380
4	3624	4,66	1,164
5	2683	6,29	1,258
6	2381	7,09	1,181

Для измерений использовано разное число потоков, 20 кластеров и 200 тыс. точек

Расчеты:

- **2 потока:** Ускорение = $16874/8300 = 2,03$ | Эффективность = $2,03/2 = 1,016$
- **3 потока:** Ускорение = $16874/4075 = 4,14$ | Эффективность = $4,14/3 = 1,380$
- **4 потока:** Ускорение = $16874/3624 = 4,66$ | Эффективность = $4,66/4 = 1,164$
- **5 потоков:** Ускорение = $16874/2683 = 6,29$ | Эффективность = $6,29/5 = 1,258$
- **6 потоков:** Ускорение = $16874/2381 = 7,09$ | Эффективность = $7,09/6 = 1,181$

Основные наблюдения:

1. Высокое ускорение параллельного алгоритма
 - На 6 потоках достигнуто ускорение 7,09x при времени выполнения 2381 мс против 16874 мс на одном потоке
 - Это свидетельствует об эффективной параллелизации алгоритма k-средних
2. Сверхлинейное ускорение
 - Эффективность превышает 1,0 на всех конфигурациях (максимум 1,38 на 3 потоках)
 - Такое явление обычно связано с:
 - Кэш-эффектами - данные распределяются между кэшами разных ядер
 - Улучшением доступа к памяти в многопоточной среде
 - Оптимизациями процессора при параллельном выполнении
3. Неравномерный рост производительности
 - Наибольший прирост между 2 и 3 потоками (удвоение ускорения)
 - После 4 потоков рост замедляется, но продолжается до 6 потоков

Вывод

В ходе выполнения лабораторной работы была реализована программа кластеризации методом k-средних с использованием POSIX потоков. Создание и синхронизация потоков подтверждены анализом вывода утилиты strace. Были изучены принципы работы системных вызовов clone(), futex() и механизмов семафоров и мьютексов. Программа показала корректную работу и позволяет исследовать ускорение при увеличении количества потоков.